



DealData

Análisis exploratorio y técnicas estadísticas del DataSet comercio electrónico Amazon

Materias: Ciencia de Datos II y Estadística y Exploración de Datos **Grupo N° 6**

Integrantes: Melania Ligorria, Miguel Rojas, Carlos Direni, Nicolás Allende, Emanuel Guaraz, Lucas Ryser, Juan Clavijo y Guadalupe Mendoza

Profesores: Nahuel Pratta y Marcos Ugarte

ANÁLISIS EXPLORATORIO Y TÉCNICAS ESTADÍSTICAS DEL DATASET COMERCIO ELECTRÓNICO AMAZON



Correlación y Regresión Lineal

La intuición sugiere que los productos con más reseñas son mejores. Los datos, sin embargo, cuentan una historia diferente.

◆ Objetivo

Evaluar si existe relación entre la cantidad de calificaciones (rating_count) y la calificación promedio (rating).

◆ Qué hicimos

Evaluación de supuestos:

- Normalidad de las variables mediante histogramas, Q-Q plots y test de Shapiro-Wilk.
- Homocedasticidad para validar la regresión.

Transformación de datos:

- Transformación logarítmica `log(1 + rating_count)` para mitigar el efecto de outliers.

Análisis de correlación y regresión lineal:

- Se aplicaron los coeficientes Pearson, Spearman y Kendall.

◆ Resultados

0.23

Correlación de Pearson

Positiva pero débil

0.055

Coeficiente de Determinación (R²)

Explica solo el 5.5% de la variabilidad del rating.

0.181

Correlación de Spearman

(p ≈ 3.4e-12) → Positiva y débil.


0.129

Correlación de Kendall

(p ≈ 2.8e-12) → Positiva y débil.

Tendencia general

Los productos con más reseñas tienden a tener ratings ligeramente mayores, pero la relación no es fuerte ni determinante.



◆ Conclusión

La popularidad no garantiza una mejor valoración. La regresión muestra una tendencia leve, pero no suficiente para predecir el rating.

El factor clave: categoría del producto (ANOVA)

◆ Qué hicimos



Análisis ANOVA

Se aplicó ANOVA de una vía con 211 categorías para ver si el **tipo de producto** influye en el rating promedio.



Significancia estadística

Se detectaron **diferencias significativas** entre categorías ($p\text{-value} \approx 1.24e-27$).



Test de Tukey Post-Hoc

Confirmó diferencias específicas: **Tarjetas de Memoria** (≈ 4.33) vs. **Controles Remotos** (≈ 3.8).


◆ Conclusión

La categoría es determinante

Si la popularidad no es un buen predictor, el análisis ANOVA reveló que **la categoría del producto** tiene un impacto estadísticamente significativo en la calificación promedio.

El tipo de producto es el factor más determinante en la valoración, permitiendo identificar qué categorías destacan o requieren mejoras.

El análisis desvela un camino claro: la calidad percibida está fuertemente ligada a la naturaleza del producto, no a su volumen de ventas o precio.



La calificación promedio de las "Tarjetas de Memoria" es consistentemente más alta que la de los "Controles Remotos", demostrando que el tipo de producto es un factor determinante.

Regresión Logística Multivariable

predicción de productos altamente calificados

◆ Qué hicimos ◆ Resultados

Aplicación de un modelo para predecir si un producto será "altamente calificado" (rating ≥ 4.0) usando variables clave.

Preprocesamiento

Creación de variable binaria (**is_highly_rated**) y transformaciones logarítmicas a precio y reseñas.

Modelo y Predictores

Entrenamiento con LogisticRegression. **Predictores clave:** **log_actual_price**, **discount_percentage**, **rating_count_log**.

Resultados

Modelo significativo ($p\text{-value} = 1.47e-13$) con Pseudo $R^2 = 0.041$ (capacidad explicativa moderada).

Influencia de variables

Precio Actual (log)


Efecto positivo y significativo. Precios más altos, mayor probabilidad de buena calificación.

Porcentaje de Descuento

Efecto negativo. Mayores descuentos, menor probabilidad de alta valoración.

Cantidad de Reseñas (log)

Efecto positivo fuerte. Más reseñas, mayor probabilidad de alta calificación.



Métricas de desempeño

0.66

Accuracy

0.66

Precision

0.91

Recall

0.76

F1 Score

0.66

AUC-ROC

Buen equilibrio entre **precisión y recall**, sin sobreajuste.

◆ Conclusión

La Regresión Logística demuestra que precio, descuento y número de reseñas influyen significativamente en la probabilidad de que un producto sea altamente calificado.

El modelo logra un desempeño moderado pero útil, capturando patrones relevantes para la toma de decisiones comerciales.

Sirve como modelo base interpretable, capaz de identificar productos con alto potencial de éxito.

Puede mejorarse con técnicas más avanzadas (como clustering o modelos multivariados) para explicar la varianza restante.